



FACULTAD DE INGENIERÍA Y ARQUITECTURA

PROGRAMA CURRICULAR DE INGENIERÍA INDUSTRIAL

ENTREGA 1 PROYECTO

Docente:

Jose Albeiro Montes Gil

Autores:

Santiago Cardona Lopez

Maria Jose Vargas Lopez

Asignatura:

Ciencia de datos

Manizales, Caldas-Colombia

2026

1. Descripción del dataset

Fuente:

El dataset “Student Lifestyle and Mental Health” parece ser un conjunto de datos sintético o recopilado para análisis académico sobre el estilo de vida y la salud mental de estudiantes universitarios de distintas carreras obtenido de Kaggle.

Número de instancias:

El dataset contiene 100,000 registros (instancias), cada uno correspondiente a un estudiante.

Número de variables:

Cuenta con 11 variables:

- Student_ID: Identificador único del estudiante
- Age: Edad del estudiante
- Gender: Género
- Department: Carrera o área de estudio
- CGPA: Promedio académico acumulado
- Sleep_Duration: Duración del sueño (horas)
- Study_Hours: Horas de estudio
- Social_Media_Hours: Horas en redes sociales
- Physical_Activity: Nivel de actividad física
- Stress_Level: Nivel de estrés (escala numérica)
- Depression: Indicador de depresión (True/False)

Variable objetivo:

La variable objetivo es:

- Depression → variable binaria (clasificación), que indica si el estudiante presenta depresión o no.

2. Análisis preliminar de los datos y visualizaciones básicas

2.1 Exploración general

- El dataset está completo, con 100,000 valores en todas las variables, lo que indica que no hay valores nulos.
- La edad de los estudiantes se encuentra entre 18 y 24 años, con un promedio de aproximadamente 21 años.
- El nivel de estrés varía entre 2 y 10, con un promedio cercano a 4.13.

2.2 Distribución de la variable objetivo

La variable Depression presenta:

- False (No depresión): ~89.9%
- True (Depresión): ~10.1%

2.3 Análisis de variables numéricas

- CGPA (rendimiento académico):
 - Se distribuye de manera continua.
 - Puede analizarse su relación con el estrés y la depresión.
- Sleep_Duration:
 - Variable clave para la salud mental.
 - Se espera que menores horas de sueño se relacionen con mayor estrés/depresión.
- Study_Hours vs Social_Media_Hours:
 - Permiten analizar hábitos de estudio vs distracción digital.
- Physical_Activity:
 - Posible variable protectora frente a la depresión.

2.4 Relaciones preliminares (insights esperados)

A partir del análisis exploratorio:

- Mayor estrés tiende a asociarse con mayor probabilidad de depresión.
- Menor duración del sueño podría correlacionarse con mayor estrés.
- Mayor uso de redes sociales puede estar relacionado con niveles más altos de estrés.
- La actividad física podría actuar como factor mitigante.

2.5 Visualizaciones de la información

1. Histograma de edades

Se observa una distribución bastante uniforme entre los 18 y 24 años, lo que indica que la muestra está bien distribuida dentro del rango típico universitario.




Figura 1. Histograma edad vs cantidad de estudiantes

2. Distribución de Nivel de estrés

La mayoría de los estudiantes se concentra en niveles de estrés entre 3 y 6, con pocos casos en niveles extremos (8–10). Esto sugiere que el estrés moderado es predominante.




Figura 2. Histograma nivel de estrés vs cantidad de estudiantes

3. Gráfico de barras de resultados con Depresión

Se observa que el desbalance entre la cantidad de personas con depresión y las que no tienen depresión es alto aproximadamente (~10%) sí presenta depresión.




Figura 3. Diagrama depresión True vs False

4. Diagrama Horas de sueño vs nivel de estrés:

Por medio de este Scatter se evidencia que con menos horas de sueño hay mayor nivel de estrés y con más horas de sueño se presenta menor estrés. Aunque no es perfectamente lineal, sí hay una relación visible.




Figura 4. Relación Horas de sueño vs nivel de estrés

2.6 Conclusión del análisis preliminar

El dataset es Grande (100k registros) lo que para este proyecto es útil y nos permite realizar entrenamiento del modelo, es Limpio (sin nulos) es decir que no requiere preprocesamiento complejo más allá de convertir dos columnas de texto a número, tiene 10 entradas y 1 salida de Falso y Verdadero.

Esto lo hace adecuado para el desarrollo de una API que nos permita predecir aproximadamente el riesgo de depresión de un estudiante con la información proporcionada.